

Laporan Akhir Machine Learning

Rekomendasi Gaya Rambut Berdasarkan Bentuk Wajah

Kelompok 02



Oleh:

11423024	:	Fernando Yosia Parhusip
11423026	:	Flora Nainggolan
11423031	:	Febri Sweeta Br Lumban Raja
11423041	:	Dewa Armada Gurusinga
11423051	:	Erwin Jeremy Sianturi

D4 TEKNOLOGI REKAYASA PERANGKAT LUNAK

FAKULTAS VOKASI

INSTITUT TEKNOLOGI DEL

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR TABEL.....	4
DAFTAR GAMBAR.....	5
1. Pendahuluan.....	6
1.1 Latar Belakang.....	6
1.2 Rumusan Masalah.....	6
1.3 Tujuan.....	7
1.4 Batasan Masalah.....	7
2. Data Collection.....	8
2.1 Sumber Data.....	8
2.2 Kelas Data Bentuk Wajah.....	8
2.3 Jumlah Data Bentuk Wajah.....	8
2.4 Jumlah Data Bentuk Wajah.....	9
3. Data Preprocessing.....	10
3.1 Pengorganisasian Dataset.....	10
3.2 Pelatihan Model Guru.....	12
3.3 Seleksi Gambar RGB.....	12
3.4 Penanganan Data Imbalance.....	13
4. Data Transformation.....	14
4.1 Resize Gambar.....	14
4.2 Preprocessing Input ResNet50V2.....	14
4.3 Data Augmentation Wajah.....	15
4.3 Transformasi Data Jenis Rambut.....	16
5. Pemodelan Machine Learning.....	17
5.1 Model Utama.....	17
5.2 Tahap Warm Up (Model Wajah).....	17
5.3 Tahap Fine Tuning (Model Wajah).....	18
5.4 Arsitektur Model Jenis Rambut (MobileNetV2).....	19
6. Evaluasi Model.....	21
6.1 Data Pengujian.....	21
6.2 Matrik Evaluasi.....	21
6.3 Hasil Evaluasi Model Wajah.....	21
6.4 Hyperparameter Tuning (Random Search).....	22
6.5 Hasil Evaluasi Model Jenis Rambut.....	22
7. Hasil Evaluasi Model Jenis Rambut.....	23
7.1 Hierarki Parameter Keputusan.....	23
7.2 Struktur Output Rekomendasi.....	23
8. Deployment dan Integrasi Model.....	24
8.1 Modifikasi Layer Inferensi.....	24
8.2 Konversi ke TensorFlow.js.....	24
9. Kesimpulan dan Pengembangan Lanjutan.....	25
9.1 Kesimpulan.....	25

9.2 Pengembangan Lanjutan.....	25
--------------------------------	----

DAFTAR TABEL

Tabel 6.1 Hasil Evaluasi Model Wajah.....	21
---	----

DAFTAR GAMBAR

Gambar 3.1 Data Preprocessing.....	10
Gambar 3.2 Pengorganisasian Dataset.....	11
Gambar 3.3 Pelatihan Model Guru.....	12
Gambar 4.1 Preprocessing Input ResNet50V2.....	14
Gambar 4.2 Data Augmentation Wajah.....	15
Gambar 4.3 Transformasi Data Jenis Rambut.....	16
5.3.1 Konfigurasi Pembekuan Lapisan (Layer Freezing).....	18
5.3.2 Kompilasi Ulang Model (Re-compilation).....	18
5.3.3 Strategi Pengkondisian dan Pengamanan Pelatihan.....	18
Gambar 5.1 Arsitektur Model Jenis Rambut.....	19

1. Pendahuluan

1.1 Latar Belakang

Penampilan fisik merupakan salah satu aspek penting yang mempengaruhi tingkat kepercayaan diri seseorang dalam interaksi sosial. Salah satu elemen utama yang menunjang penampilan adalah gaya rambut. Namun, banyak individu yang sering merasa kurang puas dengan hasil potongan rambut mereka setelah mengunjungi barbershop atau salon. Ketidakpuasan ini umumnya terjadi karena kurangnya pemahaman mengenai kesesuaian antara gaya rambut yang dipilih dengan proporsi dan bentuk wajah alami mereka.

Setiap orang memiliki bentuk wajah yang unik dan berbeda seperti Oval, Bulat (*Round*), Persegi (*Square*), Hati (*Heart*), dan Lonjong (*Oblong*) di mana masing-masing bentuk membutuhkan gaya potongan yang spesifik untuk menonjolkan fitur terbaik wajah dan menyeimbangkan proporsi visual. Selain bentuk wajah, jenis rambut mempengaruhi kesesuaian suatu gaya. Penelitian ini menyalin dataset berlabel awal ke direktori lima kelas untuk melatih model guru, kemudian mengelompokkan citra RGB FFHQ berdasarkan pseudo-label hasil prediksi model guru. Oleh karena itu, rekomendasi disusun dengan mempertimbangkan hasil klasifikasi bentuk wajah, hasil klasifikasi jenis rambut, dan kelompok demografi pengguna. Di sisi lain, kapster atau pemangkas rambut seringkali dihadapkan pada kesulitan ketika pelanggan meminta potongan yang sedang tren tanpa mempertimbangkan kecocokan dengan bentuk wajah mereka.

Oleh karena itu, diperlukan sebuah pendekatan atau sistem yang dapat memberikan rekomendasi gaya rambut secara terstruktur berdasarkan klasifikasi bentuk wajah. Rekomendasi yang dihasilkan masih perlu divalidasi bersama kapster dan pengguna. Dengan adanya rekomendasi yang akurat, pelanggan dapat membuat keputusan yang lebih tepat sebelum memotong rambut, serta meningkatkan standar pelayanan dan efisiensi waktu konsultasi di tempat potong rambut.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam pembahasan ini adalah:

1. Bagaimana mengklasifikasikan berbagai bentuk wajah manusia untuk keperluan penataan rambut?
2. Bagaimana mengklasifikasikan jenis atau tekstur rambut sebagai parameter tambahan pendukung gaya?
3. Bagaimana menentukan gaya rambut yang paling sesuai dan proporsional untuk masing-masing bentuk wajah dan jenis rambut?
4. Bagaimana merancang panduan atau alur rekomendasi yang dapat mempermudah pelanggan dalam memilih gaya rambut yang tepat?

1.3 Tujuan

Adapun tujuan dari penyusunan rancangan ini adalah:

1. Mengidentifikasi dan mengkategorikan bentuk wajah umum serta jenis rambut yang menjadi acuan dasar dalam pemilihan gaya rambut.
2. Memetakan dan merekomendasikan gaya potongan rambut yang spesifik dan optimal untuk setiap tipe bentuk wajah dan tekstur rambut.
3. Menyediakan referensi yang jelas dan terstruktur untuk meningkatkan kepuasan pelanggan serta mendukung efisiensi pelayanan dalam penataan rambut.

1.4 Batasan Masalah

Agar pembahasan lebih terarah dan tidak meluas, maka ditetapkan batasan masalah sebagai berikut:

1. Klasifikasi bentuk wajah dibatasi pada lima bentuk utama yang paling umum: Oval, Bulat (*Round*), Persegi (*Square*), Hati (*Heart*), dan Lonjong (*Oblong*).
2. Klasifikasi jenis rambut dibatasi pada lima kategori tekstur utama: Lurus (*Straight*), Bergelombang (*Wavy*), Keriting (*Curly*), Gimbal (*Dreadlocks*), dan Kribo (*Kinky*).
3. Sistem rekomendasi gaya rambut dirancang agar dapat menjangkau target demografi yang lebih luas dengan membaginya ke dalam 4 (empat) aturan utama: Pria Dewasa, Remaja Pria, Wanita Dewasa, dan Remaja Wanita.

4. Parameter rekomendasi difokuskan murni pada estetika visual, dan tidak memperhitungkan faktor biologi rambut secara mendalam seperti tingkat kerontokan ekstrem atau kondisi medis pada kulit kepala.

2. Data Collection

2.1 Sumber Data

Data yang digunakan dalam proyek ini merupakan data sekunder yang diperoleh dari *platform* penyedia dataset publik, yaitu Kaggle dan google drive. Dataset yang menjadi model guru berjudul "Dataset Faceshape" yang dipublikasikan oleh Niten Lama. Penggunaan dataset dari Kaggle dipilih karena sangat relevan dengan pemodelan yang sedang dibangun. Dataset ini dapat diakses secara publik melalui tautan:

<https://www.kaggle.com/datasets/niten19/face-shape-dataset?select=FaceShape+Dataset>.

Face Shape Dataset digunakan sebagai data berlabel awal untuk melatih model guru. Citra FFHQ digunakan sebagai sumber citra RGB yang kemudian diseleksi berdasarkan deteksi wajah, gender, dan usia, lalu diberi pseudo-label bentuk wajah oleh model guru. Dataset jenis rambut diperoleh dari Hair Type Dataset. Dataset terdiri atas 1.987 citra dari limakelas: Straight, Wavy, curly, dreadlocks, dan kinky, yang dipetakan menjadi Lurus, Bergelombang, Keriting, Gimbal, dan Kribo. Berdasarkan pembagian pada notebook, 1.592 citra digunakan sebagai data latih dan 395 citra sebagai data validasi. Penggunaan dataset dari google Drive dipilih karena memiliki kualitas yang baik dan berwarna sehingga relevan dengan input dari pengguna. Dataset ini dapat diakses secara publik melalui tautan:

<https://drive.google.com/drive/folders/1u2xu7bSrWxbUxk-dT-UvEJq8IjdmNTP>

2.2 Kelas Data Bentuk Wajah

Dataset yang digunakan dalam penelitian ini dikategorikan berdasarkan klasifikasi bentuk wajah. Berdasarkan komposisi datanya, variabel target pada dataset ini terbagi menjadi 5 (lima) kelas utama, yaitu:

- Oval

- Bulat
- Persegi
- Hati
- Lonjong

2.3 Jumlah Data Bentuk Wajah

Dataset berlabel awal untuk model guru terdiri atas 3.986 citra grayscale. Setelah model guru dilatih, citra RGB dari FFHQ diseleksi dan diberi pseudo-label hingga setiap kelas berjumlah 3.000 citra. Dengan demikian, dataset akhir bentuk wajah berjumlah 15.000 citra RGB hasil pseudo-labeling.

Data ini memiliki distribusi yang seimbang (*balanced dataset*), di mana setiap kelasnya masing-masing memiliki tepat **3.000** sampel data. Volume data yang proporsional dan berjumlah besar ini dinilai sangat memadai untuk proses pelatihan model agar terhindar dari bias kelas (*class imbalance*) dan menghasilkan performa klasifikasi yang baik.

2.4 Jumlah Data Jenis Rambut

Untuk mendukung model deteksi tekstur rambut, sistem menggunakan dataset sekunder tambahan dari Kaggle yang berjudul “hair-type-dataset” (dipublikasikan oleh Kavyasree B). Dataset ini diekstrak dan dipetakan ke dalam bahasa Indonesia untuk mempermudah keluaran (*output*) pada aplikasi. Total dataset ini terdiri dari 1.987 citra yang terbagi menjadi 1.592 citra pelatihan dan 395 citra validasi, mencakup 5 kelas: Lurus, Bergelombang, Keriting, Gimbal, dan Kribo.

3. Data Preprocessing

```
---  
--- Membersihkan Sisa File dan Menyiapkan Ulang Model Guru ---  
Mengekstrak file ZIP dataset Grayscale...  
Memuat gambar ke memori untuk pelatihan...  
Found 3986 files belonging to 5 classes.  
Epoch 1/10  
125/125 ----- 15s 64ms/step - accuracy: 0.3199 - loss: 1.6014  
Epoch 2/10  
125/125 ----- 5s 39ms/step - accuracy: 0.5341 - loss: 1.1736  
Epoch 3/10  
125/125 ----- 5s 40ms/step - accuracy: 0.6427 - loss: 0.9488  
Epoch 4/10  
125/125 ----- 5s 40ms/step - accuracy: 0.7439 - loss: 0.6840  
Epoch 5/10  
125/125 ----- 5s 39ms/step - accuracy: 0.8407 - loss: 0.4511  
Epoch 6/10  
125/125 ----- 5s 41ms/step - accuracy: 0.9202 - loss: 0.2484  
Epoch 7/10  
125/125 ----- 10s 40ms/step - accuracy: 0.9594 - loss: 0.1381  
Epoch 8/10  
125/125 ----- 5s 41ms/step - accuracy: 0.9824 - loss: 0.0747  
Epoch 9/10  
125/125 ----- 5s 40ms/step - accuracy: 0.9772 - loss: 0.0779  
Epoch 10/10  
125/125 ----- 5s 40ms/step - accuracy: 0.9887 - loss: 0.0474  
Guru siap!  
  
--- Memeriksa Data yang Sudah Ada di Drive ---  
- heart sudah berisi: 3000 foto  
- oblong sudah berisi: 3000 foto  
- oval sudah berisi: 3000 foto  
- round sudah berisi: 3000 foto  
- square sudah berisi: 3000 foto  
Total gambar yang sudah aman: 15000 foto.  
Semua folder sudah mencapai kuota 3000! Proses selesai.
```

Gambar 3.1 Data Preprocessing

3.1 Pengorganisasian Dataset

```

kelas_wajah = ['heart', 'oblong', 'oval', 'round', 'square']
for kelas in kelas_wajah:
    os.makedirs(os.path.join(ORGANIZED_TRAIN_DIR, kelas), exist_ok=True)

for root, dirs, files in os.walk(EXTRACT_TARGET_DIR):
    for f in files:
        if f.lower().endswith(('png', 'jpg', 'jpeg')):
            nama_file_kecil = f.lower()
            for kelas in kelas_wajah:
                if kelas in nama_file_kecil:
                    shutil.copy2(os.path.join(root, f), os.path.join(ORGANIZED_TRAIN_DIR, kelas, f))
                    break

print("Memuat gambar ke memori untuk pelatihan...")
train_ds = tf.keras.utils.image_dataset_from_directory(
    ORGANIZED_TRAIN_DIR, image_size=IMG_SIZE, color_mode='grayscale', batch_size=32
)

```

Gambar 3.2 Pengorganisasian Dataset

Proses awal dalam tahap pra pemrosesan data difokuskan pada pembagian dataset agar terstruktur dengan baik dan siap digunakan untuk pelatihan. Langkah ini dimulai dengan mengekstrak file arsip ZIP dan mengelompokkan gambar ke dalam direktori berdasarkan lima kelas bentuk wajah, yaitu *heart*, *oblong*, *oval*, *round*, dan *square*. Setelah pengelompokan selesai, dataset didistribusikan ke dalam beberapa subset direktori untuk memisahkan data yang akan dipelajari oleh model dan data yang akan digunakan untuk pengujian.

Pembagian dataset tersebut dilakukan secara terstruktur dengan proporsi sebagai berikut:

- Data latih (*train*) dialokasikan sebanyak 2.400 gambar per kelas.
- Data validasi (*val*) dialokasikan sebanyak 300 gambar per kelas.
- Data uji (*test*) dialokasikan sebanyak 300 gambar per kelas.

3.2 Pelatihan Model Guru

```
class_names = train_ds.class_names

model = models.Sequential([
    layers.Rescaling(1./255, input_shape=(224, 224, 1)),
    layers.Conv2D(32, 3, activation='relu'), layers.MaxPooling2D(),
    layers.Conv2D(64, 3, activation='relu'), layers.MaxPooling2D(),
    layers.Flatten(),
    layers.Dense(128, activation='relu'),
    layers.Dense(len(class_names), activation='softmax')
])
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy', metrics=['accuracy'])
model.fit(train_ds, epochs=10, verbose=1)
print("Guru siap!")
```

Gambar 3.3 Pelatihan Model Guru

Untuk mengotomatisasi proses pelabelan dan memastikan gambar yang masuk sesuai dengan kategori wajah, diimplementasikan sebuah arsitektur model sekuensial sederhana yang bertindak sebagai model guru (*teacher model*). Model ini dibangun dengan beberapa *layer* konvolusi dan dilatih secara khusus menggunakan citra berskala keabuan (*grayscale*) selama 10 *epoch*. Notebook tidak menyediakan data validasi dan data uji terpisah untuk model guru. Akurasi pelatihan 98,87% tidak dapat digunakan sebagai bukti akurasi generalisasi. Oleh karena itu, label yang dihasilkan disebut pseudo-label. Tujuan utama dari pengadaan model guru ini adalah untuk memprediksi dan mengklasifikasikan bentuk wajah dari dataset mentah secara cepat, sebelum gambar dalam format RGB disalin ke dalam direktori akhir.

3.3 Seleksi Gambar RGB

Agar kualitas data yang akan digunakan untuk melatih model utama tetap terjaga, dilakukan tahap seleksi gambar RGB secara otomatis menggunakan pustaka MTCNN digunakan sebagai backend pendeteksi wajah, sedangkan DeepFace memperkirakan gender dan usia. Model guru CNN digunakan untuk menentukan pseudo-label bentuk wajah. Proses penyaringan ini menerapkan kriteria yang sangat ketat untuk memastikan bahwa wajah yang diekstrak benar-benar relevan dengan target segmentasi pengguna sistem.

- Objek wajah yang terdeteksi wajib berjenis kelamin pria (*Man* atau *male*) dengan tingkat probabilitas keyakinan model di atas 90%.
- Estimasi usia subjek pada gambar harus berada di atas atau sama dengan 20 tahun.

3.4 Penanganan Data Imbalance

Masalah ketidakseimbangan jumlah data antar kelas (*data imbalance*) merupakan kendala yang dapat menyebabkan model cenderung bias terhadap kelas mayoritas. Untuk mencegah hal tersebut, pengumpulan data pada tahapan *preprocessing* diatur secara terprogram agar jumlah sampel di setiap kelas wajah terisi sama rata. Sistem akan terus mencari dan menyeleksi gambar mentah hingga target jumlah data terpenuhi untuk seluruh kategori.

Pendekatan konkret yang dilakukan dalam menangani potensi ketidakseimbangan data ini adalah:

- Membatasi kuota maksimal pengumpulan data sebanyak tepat 3.000 gambar untuk masing-masing kelas.
- Mengakumulasikan total dataset akhir menjadi 15.000 gambar yang dibatasi menjadi 3.000 citra hasil prediksi per kelas. Keseimbangan jumlah tidak menjamin keseimbangan kualitas atau kebenaran pseudo-label.

4. Data Transformation

Tahapan transformasi data merupakan langkah krusial untuk memastikan format dan nilai piksel dari gambar mentah sesuai dengan kebutuhan komputasi arsitektur model *Deep Learning* yang digunakan. Selain itu, tahap ini juga berperan penting dalam meningkatkan variasi dataset latih agar model yang dihasilkan memiliki kemampuan generalisasi yang baik dan tidak mudah mengalami *overfitting*.

4.1 Resize Gambar

Sebagian besar citra wajah mentah yang telah dikumpulkan memiliki resolusi asli yang beragam dan berukuran cukup besar (seperti 1024x1024 piksel). Agar proses pelatihan berjalan lebih efisien dan matriks gambar dapat diproses oleh model, ukuran gambar perlu diseragamkan. Penyesuaian dimensi ini mutlak dilakukan karena arsitektur jaringan saraf tiruan membutuhkan bentuk input yang statis.

Penerapan *resize* gambar dalam sistem ini meliputi:

- Menyeragamkan seluruh dimensi citra masukan menjadi ukuran 224 x 224 piksel.
- Menerapkan ukuran standar tersebut di berbagai fase, mulai dari pemuatan dataset latih dan validasi (`image_dataset_from_directory`), penyiapan gambar untuk diprediksi oleh model guru, hingga tahap inferensi yang direncanakan pada aplikasi web menggunakan model [TensorFlow.js](#)

4.2 Preprocessing Input ResNet50V2

```
x = tf.keras.applications.resnet_v2.preprocess_input(x)
```

Gambar 4.1 Preprocessing Input ResNet50V2

Mengingat model utama dibangun dengan memanfaatkan Transfer Learning dari arsitektur ResNet50V2 (yang sebelumnya dilatih dengan dataset ImageNet), maka data yang dimasukkan harus memiliki standar rentang nilai yang identik dengan

proses pelatihan aslinya. Normalisasi biasa tidak cukup, sehingga diperlukan fungsi pra proses khusus yang dirancang untuk arsitektur tersebut.

Langkah konkret pada tahap *preprocessing input* ini meliputi:

- Melakukan *scaling* dan transformasi nilai piksel menggunakan fungsi bawaan `tf.keras.applications.resnet_v2.preprocess_input`
- Mengkonversi nilai warna citra RGB sedemikian rupa agar distribusinya sesuai dengan ekspektasi *layer-layer* konvolusi awal pada struktur model ResNet.

4.3 Data Augmentation Wajah

```
# 1. MEMBANGUN ARSITEKTUR TERBAIK
# =====
print("\nMembangun model dengan arsitektur terbaik...")
data_augmentation = tf.keras.Sequential([
    layers.RandomFlip("horizontal"),
    layers.RandomRotation(0.1),
    layers.RandomZoom(0.1),
], name="data_augmentation")
```

Gambar 4.2 Data Augmentation Wajah

Untuk meningkatkan ketangguhan model, terutama mengingat model yang kompleks sangat rentan terhadap *overfitting* (hanya menghafal data latih), sistem menerapkan teknik augmentasi data (*data augmentation*). Proses ini ditambahkan sebagai sebuah *layer Sequential* di awal model untuk memodifikasi citra secara acak dan langsung pada saat proses pelatihan (*on-the-fly*). Hal ini membuat model selalu melihat variasi gambar yang sedikit berbeda pada setiap *epoch*.

Teknik augmentasi data yang dikonfigurasi dalam sistem meliputi:

- **Random Flip ("horizontal"):** Membalikkan gambar secara horizontal (seperti pantulan cermin) untuk melatih model mengenali bentuk wajah terlepas dari sisi mana gambar diambil.
- **Random Rotation (0.1):** Memutar gambar secara acak sebesar maksimal 10% (sekitar 36 derajat) untuk menyimulasikan ketidaksempurnaan sudut pengambilan foto di mana kepala subjek mungkin sedikit miring.

- **Random Zoom (0.1):** Memperbesar atau memperkecil gambar secara acak hingga skala 10% untuk menyimulasikan variasi jarak antara kamera dengan wajah pengguna.

4.3 Transformasi Data Jenis Rambut

```
import os
import tensorflow as tf
from tensorflow.keras.preprocessing.image import ImageDataGenerator
import glob

# (Straight, Wavy, curly, dreadlocks, kinky)
kategori_indo = {
    'Straight': 'Lurus',
    'Wavy': 'Bergelombang',
    'curly': 'Keriting',
    'dreadlocks': 'Gimbal',
    'kinky': 'Kribo'
}

for indo in kategori_indo.values():
    os.makedirs(f"hair_filtered/train/{indo}", exist_ok=True)
```

Gambar 4.3 Transformasi Data Jenis Rambut

Berbeda dengan dataset wajah, pra pemrosesan dataset jenis rambut menggunakan modul `ImageDataGenerator` dari Keras. Transformasi yang diterapkan meliputi *rescale* ($1./255$) untuk menormalisasi nilai piksel, pembagian validasi sebesar 20%, pengaturan *horizontal flip*, dan rotasi gambar hingga rentang 20 derajat (*rotation_range=20*).

5. Pemodelan Machine Learning

5.1 Model Utama

Arsitektur model utama dibangun dengan mengintegrasikan blok ekstraksi fitur bawaan berkemampuan tinggi yang dihubungkan ke struktur jaringan saraf tiruan kustom (*top layers*). Blok kustom ini ditambahkan di ujung arsitektur untuk memetakan fitur abstrak menjadi keputusan klasifikasi. Lapisan akhir ini disusun menggunakan arsitektur sekuensial yang melingkupi beberapa komponen penting penunjang performa komputasi.

Struktur pembentuk dari bagian *top layers* pada model utama meliputi:

- **GlobalAveragePooling2D**
Mengurangi dimensi spasial dari matriks fitur hasil konvolusi secara efisien sekaligus meminimalkan jumlah parameter untuk mencegah *overfitting*.
- **Dense Layer (384 Neuron, Aktivasi 'relu')**
Lapisan terhubung penuh (*fully-connected*) yang bertindak sebagai unit penalaran utama untuk mengenali kombinasi pola bentuk wajah pria dewasa.
- **Dropout Layer (0.4)**
Lapisan pengaman yang menonaktifkan 40% neuron secara acak selama pelatihan guna memaksa jaringan mempelajari fitur yang lebih kuat dan tidak bergantung pada neuron tertentu.
- **Dense Output Layer (5 Neuron, Aktivasi 'softmax')**
Lapisan terakhir yang menghasilkan distribusi nilai probabilitas untuk menentukan representasi akhir dari lima kelas bentuk wajah target (*heart, oblong, oval, round, square*).

5.2 Tahap Warm Up (Model Wajah)

Sebelum model utama mengeksplorasi dataset bentuk wajah secara mendalam, diterapkan fase pemanasan (*warm-up phase*) selama 5 *epoch*. Pada tahap awal ini, seluruh bobot jaringan asli di dalam ResNet50V2 dikunci sepenuhnya (`base_model.trainable = False`). Pelatihan sengaja difokuskan hanya pada lapisan *Dense kustom* yang baru saja ditambahkan di ujung model menggunakan *Learning Rate* standar sebesar 10^{-3} (\$1e-3) dengan *optimizer* Adam.

Tujuan utama dilaksanakannya tahapan *warm-up* ini meliputi:

- Menyelamatkan dan menjaga integritas bobot original (*pretrained weights*) ResNet50V2 agar tidak rusak oleh nilai gradien yang tidak stabil pada awal pelatihan.
- Memberikan waktu bagi lapisan klasifikasi kustom untuk beradaptasi dan menyesuaikan bobot acaknya secara perlahan agar selaras dengan pola fitur visual yang dikirimkan oleh *base model*.

5.3 Tahap Fine Tuning (Model Wajah)

Setelah fase pemanasan (*warm-up*) selesai dan lapisan ujung (*dense layer*) mulai stabil, model dipindahkan ke tahapan *Fine-Tuning*. Tahap ini bertujuan untuk membuka kapasitas adaptasi penuh dari arsitektur model terhadap karakteristik dataset yang baru.

Secara teknis, proses yang terjadi pada fase ini dapat dibagi menjadi beberapa bagian utama:

5.3.1 Konfigurasi Pembekuan Lapisan (Layer Freezing)

- Membuka Kunci Bobot
Gembok seluruh lapisan pada arsitektur ResNet50V2 dibuka kembali agar bobotnya dapat diperbarui.
- Pembekuan Parsial
Sistem mengunci kembali 100 lapisan pertama (`base_model.layers[:100]`). Langkah ini diambil karena lapisan-lapisan awal tersebut sudah sangat optimal dalam mengenali fitur visual mendasar (*low-level features* seperti garis, tepi, dan warna) dari bobot ImageNet, sehingga tidak perlu dilatih ulang.

5.3.2 Kompilasi Ulang Model (*Re-compilation*)

Proses kompilasi ulang dijalankan menggunakan pengaturan optimasi yang ketat guna menjaga stabilitas model:

- Optimizer: Menggunakan algoritma Adam.
- Learning Rate: Diatur sangat kecil, yaitu sebesar $1e-5$.

5.3.3 Strategi Pengkondisian dan Pengamanan Pelatihan

Untuk memastikan proses *Fine-Tuning* berjalan optimal tanpa merusak performa dasar model, diterapkan tiga strategi pengamanan utama:

- **Pemanfaatan Learning Rate Rendah ($1e-5$)**
Digunakan agar modifikasi bobot pada sisa lapisan ResNet50V2 berjalan secara mikro (halus). Hal ini krusial untuk mempelajari detail anatomis wajah baru

(*micro-features* seperti sudut rahang dan kelengkungan dagu) secara perlahan tanpa merusak (*catastrophic forgetting*) pemahaman visual umum yang sudah dimiliki model sebelumnya.

- **Mekanisme EarlyStopping**

Bertindak sebagai pengaman otomatis yang dikonfigurasi dengan parameter `patience=5`. Fungsi ini akan menghentikan proses pelatihan secara paksa apabila akurasi validasi (`val_accuracy`) tidak lagi menunjukkan tren kenaikan dalam 5 *epoch* berturut-turut, sehingga model terhindar dari fenomena *overfitting*.

- **Penerapan ModelCheckpoint (Sistem Auto-Save)**

Modul ini bertindak sebagai sistem penyimpanan otomatis yang mendeteksi peningkatan performa di setiap *epoch*. Dengan parameter `save_best_only=True`, sistem hanya akan mengunci dan menyimpan model dengan performa terbaik ke dalam direktori penyimpanan secara permanen dalam format `.keras`.

5.4 Arsitektur Model Jenis Rambut (MobileNetV2)

```
from tensorflow.keras.applications import MobileNetV2
from tensorflow.keras.layers import Dense, GlobalAveragePooling2D, Dropout
from tensorflow.keras.models import Model

# Menggunakan MobileNetV2
base_model_hair = MobileNetV2(weights="imagenet", include_top=False, input_shape=(224, 224, 3))
base_model_hair.trainable = False

x = base_model_hair.output
x = GlobalAveragePooling2D()(x)
x = Dense(128, activation="relu")(x)
x = Dropout(0.5)(x)
predictions_hair = Dense(train_generator.num_classes, activation="softmax")(x)

model_hair = Model(inputs=base_model_hair.input, outputs=predictions_hair)
model_hair.compile(optimizer="adam", loss="categorical_crossentropy", metrics=["accuracy"])

# Training
history_hair = model_hair.fit(
    train_generator,
    epochs=5,
    validation_data=val_generator
)
```

Gambar 5.1 Arsitektur Model Jenis Rambut

Untuk model klasifikasi jenis rambut, diimplementasikan arsitektur MobileNetV2 (*pre-trained ImageNet*). Pemilihan MobileNetV2 didasarkan pada komputasinya yang sangat ringan (ukuran *file* hasil latih hanya sekitar 10MB), sehingga sangat optimal untuk integrasi

aplikasi *client-side*. *Base model* ini dikunci dan ditambah *GlobalAveragePooling2D*, sebuah *Dense layer* (128 neuron), *Dropout* (0.5), serta *Output layer* (5 neuron softmax).

6. Evaluasi Model

6.1 Data Pengujian

Data pengujian (*test dataset*) yang digunakan pada tahap ini terdiri dari 1.500 citra wajah yang belum pernah dilihat oleh model selama masa pelatihan (*unseen data*). Dataset uji ini didistribusikan secara seimbang (*balanced dataset*), di mana masing-masing dari 5 kelas bentuk wajah (*Heart, Oblong, Oval, Round, dan Square*) memiliki representasi sebanyak 300 gambar. Seluruh citra telah melalui tahap *preprocessing* yang sama dengan data latih, termasuk penyesuaian dimensi menjadi 224×224 piksel.

6.2 Matrik Evaluasi

Untuk mengukur efektivitas dan kemampuan generalisasi model secara komprehensif, pengujian ini menggunakan dua instrumen evaluasi utama:

- **Classification Report**

Metrik kuantitatif yang mencakup nilai *Precision* (tingkat ketepatan prediksi positif), *Recall* (tingkat sensitivitas model menemukan kelas yang benar), *F1-Score* (rata-rata harmonik dari *precision* dan *recall*), serta *Accuracy* (akurasi keseluruhan).

- **Confusion Matrix (Matriks Kebingungan)**

Visualisasi grafis berbentuk *heatmap* yang digunakan untuk memetakan secara spesifik prediksi benar dan salah (*misclassification*) pada setiap kelas, sehingga diketahui letak bias model.

6.3 Hasil Evaluasi Model Wajah

Setelah diuji pada 1.500 citra wajah, model *Fine-Tuned ResNet50V2* menghasilkan matriks performa berikut:

Tabel 6.1 Hasil Evaluasi Model Wajah

Kelas Wajah	Precision	Recall	F1-Score	Support
Heart	0.48	0.37	0.42	300
Oblong	0.40	0.47	0.43	300
Oval	0.67	0.43	0.53	300
Round	0.40	0.43	0.42	300
Square	0.39	0.52	0.45	300

Accuracy	0.45	1500
----------	------	------

Rata-rata akurasi validasi model berada pada angka 45%, dengan presisi pengenalan tertinggi berada pada kategori bentuk wajah **Oval** (0.67).

6.4 Hyperparameter Tuning (Random Search)

Sebagai pemenuhan standar proyek *Machine Learning*, proses pencarian parameter terbaik (*hyperparameter tuning*) dieksekusi menggunakan pustaka **KerasTuner** dengan algoritma *Random Search*. Parameter yang dieksplorasi meliputi tingkat *Dropout* (0.2 hingga 0.5), penambahan unit *Dense Layer* ekstra, dan konfigurasi *Learning Rate*. Kombinasi terbaik yang berhasil ditemukan dan diaplikasikan pada arsitektur final adalah:

- **Dropout Rate:** 0.3
- **Dense Layer Ekstra:** Ya (256 neuron)
- **Learning Rate:** 0.0001 (1e-4)

6.5 Hasil Evaluasi Model Jenis Rambut

Model klasifikasi jenis rambut (MobileNetV2) yang dilatih selama 5 epoch berhasil menunjukkan performa pembelajaran yang sangat cepat dan impresif. Pada epoch terakhir, akurasi data *training* mencapai 83.29%, sedangkan akurasi pada data validasi menyentuh 81.5%.

7. Hasil Evaluasi Model Jenis Rambut

Sebagai sistem inti untuk menghubungkan hasil prediksi kecerdasan buatan dengan keluaran yang dapat dibaca manusia, dibangun sebuah *Rule-Based Engine* berskala besar yang dikodekan ke dalam format struktur data JSON.

7.1 Hierarki Parameter Keputusan

Logika rekomendasi bekerja secara hierarkis (bercabang) dengan menerima 3 *input* utama:

1. Demografi Pengguna (Pria Dewasa / Remaja Pria / Wanita Dewasa / Remaja Wanita).
2. Hasil Prediksi Model 1: Bentuk Wajah (Heart, Oblong, Oval, Round, Square).
3. Hasil Prediksi Model 2: Jenis Rambut (Lurus, Bergelombang, Keriting, Gimbal, Kribo).

7.2 Struktur Output Rekomendasi

Setiap kombinasi unik dari parameter di atas akan mengakses satu node JSON spesifik yang berisi himpunan rekomendasi (array of recommendations). Setiap elemen rekomendasi dirancang untuk sangat deskriptif dan berisi struktur data:

- name: Nama potongan gaya rambut (misal: *French Crop*, *Textured Fringe*).
- reason: Alasan logis mengapa gaya ini proporsional (misal: "Poni memendekkan tinggi wajah secara visual").
- barber_note: Instruksi teknis potong untuk diberikan kepada kapster.
- priority: Tingkat relevansi gaya (Sangat Disarankan, Aman, Trendy, dll).

8. Deployment dan Integrasi Model

Untuk memastikan sistem dapat diimplementasikan ke dalam *dashboard web* (seperti ekosistem Laravel) tanpa membebani server dengan komputasi model Deep Learning yang berat, diterapkan strategi *Client-Side Inference*.

8.1 Modifikasi Layer Inferensi

Sebelum diekspor, struktur model ResNet50V2 dirakit ulang melalui kode Python untuk menghapus *layer* *data_augmentation*. Hal ini mutlak dilakukan karena augmentasi hanya relevan pada saat pelatihan, dan kehadirannya pada saat inferensi dapat mengganggu pembacaan matriks gambar oleh *browser*.

8.2 Konversi ke TensorFlow.js

Model akhir yang bersih (.keras dan .h5) dikonversi secara terprogram menggunakan *library* *tensorflowjs_converter*. Proses konversi ini menghasilkan serangkaian arsip *sharded binary weights* (.bin) dan *topology/manifest file* (.json) yang siap dibaca oleh lingkungan JavaScript langsung di perangkat pengguna (*browser / smartphone*).

9. Kesimpulan dan Pengembangan Lanjutan

9.1 Kesimpulan

Berdasarkan serangkaian tahapan mulai dari pengumpulan data hingga *deployment*, dapat ditarik kesimpulan:

1. **Interpretasi Visual:** Klasifikasi bentuk wajah manusia merupakan tugas yang sangat kompleks karena perbedaan antar kelas (*micro-features* seperti sudut rahang tipis) sangat tersamar dibandingkan deteksi objek umum.
2. **Keseimbangan Performa:** Meskipun model klasifikasi wajah mencatat akurasi menengah (45%), model pendeteksi jenis tekstur rambut (MobileNetV2) berhasil mencetak akurasi tinggi (81.5%).
3. **Utilitas Sistem:** Sistem aturan (*rules*) rekomendasi berbasis JSON bertindak sebagai jembatan yang sangat kuat. Kombinasi AI dan *Rule-Based Engine* ini berhasil menciptakan sistem rekomendasi objektif yang terstandarisasi untuk ekosistem UMKM Barbershop/Salon.

9.2 Pengembangan Lanjutan

Untuk mendongkrak metrik pengenalan pola wajah secara signifikan di masa mendatang, sangat direkomendasikan untuk mengintegrasikan modul **Auto-Cropping**. Dengan menerapkan deteksi wajah otomatis (seperti MediaPipe atau MTCNN) pada tahap inferensi pengguna, gambar *input* dapat dipotong ketat (hanya menampilkan area dagu hingga dahi), sehingga arsitektur *Deep Learning* terbebas dari kebingungan (*noise*) yang ditimbulkan oleh latar belakang, leher, atau pakaian pengguna.